

Documentación Técnica: Asesor de IA Empresarial

Documentación Técnica:

https://docs.google.com/document/d/12PXmvlXihpM1-ijiaUAsr9-JDWvn3vy7AH8cMGY0gPY/edit?usp=drive_link

Archivo del flujo: https://drive.google.com/file/d/1s_Qnd3rX5X3DePJb5plB8XgKy08VBhUO/view?usp=sharing


Enlace al Dashboard de Control (KPIs): <https://airtable.com/appgNVhYkjS3yHJyQ/paggFWUu7TRny03TS>

Enlace a la Base de Datos (Read-Only): <https://airtable.com/appgNVhYkjS3yHJyQ/shrJfxn5QGJRFcXuy>


Video Demo: <https://drive.google.com/file/d/14oWEXGjHcCzkrvgCPE7AvfXlqofU3Kzs/view?usp=sharing>

1. Mapa de Arquitectura del Sistema


WorkFlow Completo::




Flujo Principal - Agente de IA:



Flujo para aprobación de cancelaciones - HITL:



Flujo de registro y aviso de errores no controlados de los nodos:



El sistema está diseñado bajo una arquitectura orientada a eventos con separación de responsabilidades:

- **Trigger Principal:** WhatsApp API que escucha mensajes entrantes.
- **Enrutador (Router):** Nodo condicional (If) que filtra saludos básicos ("hola", "menú", "start") para responder directamente sin consumir tokens de IA, enviando solo consultas complejas al motor principal.
- **Motor de IA (Orquestador Lógico):** Agente de IA impulsado por LLM, equipado con memoria conversacional (límite de 10 mensajes) y acceso a herramientas estructuradas (Tools).
- **Capa de Datos (Herramientas):** Nodos de Airtable separados por función (Búsqueda de Inventario, Lectura de Políticas, Consulta de Cancelaciones y Creación de Cancelaciones).
- **Human-in-the-Loop (HITL):** Flujo asíncrono disparado por Airtable ante una nueva cancelación, que envía un correo interactivo por Gmail esperando la resolución humana (Aprobado/Rechazado) antes de notificar vía Slack y actualizar la base de datos.
- **Manejador de Errores Local (Agente IA):** Si el motor de inteligencia artificial experimenta una caída, el flujo escapa por una ruta dedicada que registra el incidente en la base de datos de Airtable, notifica al cliente mediante WhatsApp para no interrumpir la experiencia del usuario, y emite una alerta inmediata al equipo de IT a través de Slack.

- **Manejador de Errores Global (Fallback):** Trigger de error ("Si algún nodo falla") que actúa como red de seguridad para el resto del sistema. Captura excepciones de cualquier otro nodo no controlado, registra el incidente en Airtable y alerta al área de IT vía Slack.

2. Manual Operativo de Datos y Estructuras

El sistema utiliza Airtable como base de datos relacional y memoria del sistema. Se compone de las siguientes tablas principales:

- **Tabla "Inventario de Productos Tecnológicos":** Almacena el catálogo de la tienda. Los campos incluyen ID, Artículo, Stock, Días de Garantía y Descripción del Artículo.
- **Tabla "Cancelaciones":** Gestiona el estado de las devoluciones. Los campos incluyen ID Cancelación, ID Venta, Vendedor, Fecha Solicitud, Monto Venta, Motivo de la cancelación, Estado (ej. En Proceso, Rechazado) y Fecha de Aprobación o Rechazo.
- **Tabla "Términos y Políticas Comerciales - Tienda de Informática":** Actúa como base de conocimiento estática para el Agente RAG. Los campos incluyen Política y Descripción.
- **Tabla "Registro de errores e incidentes":** Bitácora técnica del sistema. Los campos incluyen ID, Fecha y Hora, Tipo de Error (ej. "Base de Datos") y Descripción (ej. "Timeout en conexión...").

Esquemas JSON de Transferencia (Integraciones):

- **WhatsApp API (Entrada):** El sistema extrae el texto del usuario navegando el JSON de Meta mediante la ruta:
`{{ $json.body.entry[0].changes[0].value.messages[0].text.body }}`.
- **Gmail HITL (Salida interactiva):** Se utiliza la operación `sendAndWait` enviando un payload estructurado con botones booleanos (`true` para Aprobado, `false` para Rechazado), pausando la ejecución en n8n hasta recibir el `callback`.

3. Matriz de Optimización de Costos (Justificación de Modelos)

Para garantizar un ecosistema escalable y rentable, se aplica una estrategia de enrutamiento de modelos (Model Routing) basada en la complejidad de la tarea:

Tarea / Nodo	Modelo Asignado	Justificación y Optimización de Costos

Enrutador Inicial (Filtro)	N/A (Lógica Tradicional)	Los saludos básicos ("hola", "start") se responden mediante nodos lógicos estándar (If). Ahorro: 100% de tokens en interacciones nulas.
Agente de IA Empresarial	GPT-4o / Claude 3.5 Sonnet	Se requiere alto razonamiento lógico para decidir qué herramienta de Airtable usar (RAG de políticas, lectura de inventario o escritura de cancelaciones). El costo mayor se justifica por la precisión en el uso de herramientas (Function Calling).
Memoria del Agente	Window Buffer (Límite: 10)	Se limita el historial a los últimos 10 mensajes. Ahorro: Previene el crecimiento exponencial del payload (evitando el límite de la ventana de contexto) y controla el costo de tokens de entrada por consulta.

4. Documentación de Seguridad y Resiliencia

El ecosistema aplica el principio de **Defensa en Profundidad**, abarcando resiliencia técnica y minimización de riesgos operativos:

1. **Minimización de Datos y Seguridad:** El Agente de IA solo tiene acceso a las herramientas estrictamente necesarias. Las credenciales (Meta, Gmail, Slack, Airtable) están cifradas dentro del gestor de credenciales nativo de n8n y no viajan en el texto plano del flujo.
2. **Manejo de Errores (Error Handlers):**
 - **Ruta Local (Frontend y Backend sincronizados):** Si el motor de IA experimenta intermitencias (ej. límite de cuota o caída de la API), la salida secundaria de "Error" del nodo principal toma el control. Esta ruta protege la experiencia del usuario enviando un mensaje automático de disculpas por WhatsApp. De forma simultánea y para no perder la trazabilidad (ya que el manejador global no actúa aquí), el sistema registra el fallo en Airtable y envía una alerta urgente por Slack al área de IT.
 - **Ruta Global (Safety Net):** Se configuró un **Error Trigger** independiente que captura caídas en el resto del ecosistema (ej. Timeout en los Webhooks iniciales, fallos en la redacción de correos de Gmail, etc.). Este nodo escribe automáticamente en la tabla

"Registro de errores e incidentes" y envía un post de emergencia al canal de Slack de IT.

3. **Human-in-the-Loop (HITL):**

- Para evitar el "Efecto Metralleta", el Agente IA **no tiene permisos** para aprobar reembolsos ni modificar el estado final de una cancelación.
- El agente solo inserta la solicitud con estado "En Proceso". Esto dispara un flujo paralelo que notifica a un supervisor por correo. Solo mediante intervención humana se modifica la base de datos a "Aprobado" o "Rechazado", mitigando riesgos financieros.

5. Dashboard de Control y Monitoreo

Para cumplir con la supervisión continua del ecosistema y medir la salud del sistema, se ha desarrollado un panel de control interactivo.

- Enlace público al Dashboard:
<https://airtable.com/appgNVhYkjS3yHJyQ/paggFWUu7TRny03TS>

(Solicitar acceso ya que no lo tengo pago al Airtable, de igual manera las capturas de la interfaz están cargadas en github)

Este panel centraliza la visualización de datos operativos, permitiendo monitorear en tiempo real:

- El estado general del inventario (stock total, promedios y distribución).
- Las métricas clave del flujo de cancelaciones (volumen, montos y tiempos de resolución).
- La tasa de errores técnicos e incidentes capturados por el manejador global.